

**ΟΙΚΟΝΟΜΙΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ
ΑΘΗΝΩΝ**

ΤΜΗΜΑ ΣΤΑΤΙΣΤΙΚΗΣ

ΕΑΡΙΝΟ ΕΞΑΜΗΝΟ

ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ

Διδάσκοντες: Ι.Ντζούφρας, Ξ.Πεντελή

ΕΡΓΑΣΙΑ 8

**ΧΡΟΝΟΙ ΓΙΑΛΥΣΜΑΤΟΣ ΤΩΝ
ΠΡΟΪΟΝΤΩΝ ΤΗΣ NAMBE MILLS**

Φοιτητής

Ονοματεπώνυμο: Πατσαμάνης Νικόλαος

Έτος σπουδών: 3^ο

Αριθμός Μητρώου: 6190108

Περιεχόμενα

1. Εισαγωγή-περιγραφή μελέτης και προβλήματος	1
2. Περιγραφική ανάλυση	2
3. Σχέσεις ανά δύο	4
4. Προβλεπτικά ή ερμηνευτικά μοντέλα	6
5. Συμπεράσματα και συζήτηση	11
Παράρτημα	12

1. Εισαγωγή – περιγραφή μελέτης και προβλήματος

Αποτελεί αδιαμφισβήτητο γεγονός ότι τα σκεύη κουζίνας είναι απαραίτητο να υπάρχουν σε κάθε σπίτι, καθώς καθίστανται ένα πολύτιμο εργαλείο για την κάλυψη μίας από της βασικότερες ανάγκες του ανθρώπου, του φαγητού. Για την κατασκευή των σκευών αυτών διεξάγονται μια σειρά ενεργειών όπως αυτή της μορφοποίησης και του γυαλίσματος. Τα προϊόντα εμφανίζουν ευδιάκριτες διαφορές σε μερικά σημεία όπως η διάμετρός τους, ο χρόνος γυαλίσματός τους καθώς και η λιανική τιμή πωλήσεώς τους. Οι διαφορές αυτές οφείλονται σε διάφορους παράγοντες.

Στόχος λοιπόν της παρούσας μελέτης, είναι να διερευνήσει τους παράγοντες τους οποίους καθορίζουν τα παρατηρούμενα χαρακτηριστικά των σκευών και να τους αξιολογήσει έτσι ώστε να μπορούν να ερμηνευτούν τα συμπεράσματα που θα προκύψουν. Τελικά, θα φτάσουμε στο σημείο να μπορούμε να προβλέψουμε χαρακτηριστικά όπως τη λιανική τιμή του προϊόντος, με βάση ορισμένων επιλεγμένων χαρακτηριστικών του. Τοιοιτοτρόπως, τα αποτελέσματα θα μπορούν να τα μελετήσουν προς συμφέρον τους τόσο οι εταιρίες που κατασκευάζουν τα σκεύη, όσο και οι καταναλωτές που τα αγοράζουν.

Για το σκοπό της μελέτης η εταιρία Nambe Mills, που κατασκευάζει τέτοιου είδους προϊόντα, σύλλεξε δεδομένα από προϊόντα που παράγει. Αυτό το σετ δεδομένων περιέχει 59 παρατηρήσεις και 7 μεταβλητές οι οποίες είναι οι ακόλουθες:

Πίνακας 1: Πίνακας δεδομένων


Αριθμός Μεταβλητής	Όνομα Μεταβλητής	Σημασία μεταβλητής	Τύπος μεταβλητής	Τιμές
1	BOWL	Είναι το σκεύος μπωλ;	Ποιοτική	0:όχι 1:ναι
2	CASS	Είναι το σκεύος κατσαρόλα;	Ποιοτική	0:όχι 1:ναι
3	DISH	Είναι το σκεύος πιάτο;	Ποιοτική	0:όχι 1:ναι
4	TRAY	Είναι το σκεύος δίσκος;	Ποιοτική	0:όχι 1:ναι
5	DIAM	Διάμετρος προϊόντος	Ποσοτική	inches (")
6	TIME	Χρόνος γυαλίσματος	Ποσοτική	λεπτά (')
7	PRICE	Τιμή Λιανικής Πώλησης	Ποσοτική	δολάρια (\$)

2. Περιγραφική ανάλυση

Για την επίτευξη της ανάλυσης θα χρησιμοποιηθεί το στατιστικό πακέτο R, με το οποίο θα διεξαχθούν οι απαραίτητοι έλεγχοι και θα απεικονιστούν τα κατάλληλα διαγράμματα. Αρχικά εισάγουμε τα δεδομένα και εγκαθιστούμε τις βιβλιοθήκες που απαιτούνται για την ανάλυσή μας. Παρατηρούμε ότι οι μεταβλητές BOWL, CASS, DISH και TRAY είναι δίτιμες κατηγορικές μεταβλητές και παρέχουν πληροφορίες σχετικά με το είδος του σκεύους. Εντούτοις, στην R έχουν καταγραφεί ως αριθμοί και γι' αυτό τα μετατρέπουμε σε κατηγορικές για δική μας διευκόλυνση. Στις κατηγορικές μεταβλητές το (1) συμβολίζει το 'ναι' και το (0) συμβολίζει το 'όχι'.

Στη συνέχεια θέλουμε να προχωρήσουμε σε περιγραφική στατιστική. Για τις 4 πρώτες μεταβλητές που είναι ποιοτικές δημιουργούμε ένα διάγραμμα πίτας στο οποίο βλέπουμε τη συχνότητα της κάθε μίας. Επιπλέον, στο διάγραμμα αυτό μας είναι εύκολο να συγκρίνουμε τις συχνότητες μεταξύ τους. Στο διάγραμμα έχει προστεθεί μία ακόμα μεταβλητή με το όνομα 'OTHER' η οποία αντιπροσωπεύει τα σκεύη που δεν ανήκουν σε κανένα είδος από τα δοθείσα.

Σχήμα 1: Πίτα κατηγορικών μεταβλητών



Όπως φαίνεται ξεκάθαρα στο διάγραμμα, οι παρατηρήσεις με το μεγαλύτερο ποσοστό είναι το είδος 'BOWL' (39%).

Για τις υπόλοιπες 3 μεταβλητές έχει ενδιαφέρον να υπολογίσουμε τα περιγραφικά μέτρα, όπως τη διάμεσο και τον μέσο.

Πίνακας 2: Πίνακας περιγραφικών μέτρων ποσοτικών μεταβλητών

	Διάμετρος προϊόντος	Χρόνος γυαλίσματος	Τιμή Λιανικής Πώλησης
Μικρότερη τιμή	5.00	12.02	21.50
1 ^ο τεταρτημόριο	8.25	22.21	47.25
Διάμεσος	11.00	31.46	75.00
Μέσος	10.93	35.82	86.38
3 ^ο τεταρτημόριο	13.00	45.03	107.00
Μέγιστη τιμή	25.00	109.38	260.00
Τυπική απόκλιση	3.85	19.02	51.57
Συμμετρία	0.83	1.48	1.15
Κύρτωση	1.47	2.59	1.20

Για να προσεγγίζει μία μεταβλητή την κανονική κατανομή θα πρέπει οι τιμές της συμμετρίας και της κύρτωσης να είναι κοντά στο 0, ενώ η διάμεσος δεν πρέπει να έχει μεγάλη απόκλιση από τον μέσο. Αν και καμία μεταβλητή δεν ακολουθεί την κανονική κατανομή, μπορούμε με ευκολία να διακρίνουμε ότι η διάμετρος προϊόντος την προσεγγίζει περισσότερο από τον χρόνο γυαλίσματος.

Επίσης, δημιουργούμε ραβδόγραμμα για κάθε μία από τις ποσοτικές μεταβλητές όπου απεικονίζεται η γραφική παράσταση των τιμών και διάγραμμα πλαισίου-απολήξεων από όπου διακρίνουμε τις ακραίες τιμές.

Έπειτα, θα προβούμε στους ελέγχους κανονικότητας Lillie test και Shapiro-Wilk test. Παρατηρούμε ότι δε μπορούμε να πούμε με υψηλή βεβαιότητα ότι κάποια από τις μεταβλητές ακολουθεί κανονική κατανομή. Αν και η μεταβλητή DIAM έχει υψηλό p-value στο lillie test (~0.78) δεν ισχύει το ίδιο και στο shapiro-wilk test (p-value~0.016). Για να πούμε ότι τα δεδομένα ακολουθούν κανονικότητα θα θέλαμε p-value>0.05 στο Shapiro-Wilk test. Το Shapiro-Wilk test είναι κατάλληλο για μικρά δείγματα ($n < 50$), ωστόσο εδώ το δείγμα μας ($n=59$) δεν είναι πολύ μεγάλο και μπορούμε να το χρησιμοποιήσουμε.

3. Σχέσεις ανά δύο


Αφού έχουμε μελετήσει τη κάθε μεταβλητή ξεχωριστά, θέλουμε εν συνεχεία να διερευνήσουμε τις σχέσεις που έχουν οι μεταβλητές μεταξύ τους. Για την διεξαγωγή των απαραίτητων ελέγχων συσχέτισης του Pearson και ανεξαρτησίας του Chi-squared θα πρέπει να μετατρέψουμε τις ποσοτικές μεταβλητές σε κατηγορικές. Οπότε τις χωρίζουμε σε 4 κατηγορίες αναλόγως με το σε πιο από τα 4 εύρη ανήκει η κάθε τιμή. Οι σχέσεις μεταβλητών που έχει ενδιαφέρον να μελετήσουμε είναι οι παρακάτω:

- Διάμετρος προϊόντος και μπωλ (DIAM~BOWL)
- Διάμετρος προϊόντος και κατσαρόλα (DIAM~CASS)
- Διάμετρος προϊόντος και πιάτο (DIAM~DISH)
- Διάμετρος προϊόντος και δίσκος (DIAM~TRAY)
- Χρόνος γυαλίσματος και μπωλ (TIME~BOWL)
- Χρόνος γυαλίσματος και κατσαρόλα (TIME~CASS)
- Χρόνος γυαλίσματος και πιάτο (TIME~DISH)
- Χρόνος γυαλίσματος και δίσκος (TIME~TRAY)
- Τιμή λιανικής πώλησης και μπωλ (PRICE~BOWL)
- Τιμή λιανικής πώλησης και κατσαρόλα (PRICE~CASS)
- Τιμή λιανικής πώλησης και πιάτο (PRICE~DISH)
- Τιμή λιανικής πώλησης και δίσκος (PRICE~TRAY)
- Διάμετρος προϊόντος και χρόνος γυαλίσματος
- Διάμετρος προϊόντος και τιμή λιανικής πώλησης
- Χρόνος γυαλίσματος και τιμή λιανικής πώλησης

Κάνοντας τους παραπάνω ελέγχους, παρατηρούμε ότι η διάμετρος του προϊόντος συσχετίζεται αρκετά τόσο με τον χρόνο γυαλίσματος όσο και με τη τιμή. Επίσης, πολύ υψηλή συσχέτιση έχουν μεταξύ τους ο χρόνος γυαλίσματος και η τιμή λιανικής πώλησης. Από το Chi-square test, κοιτάζοντας τα p-value (θέλουμε $p\text{-value} < 0.05$ για να πούμε με αρκετή σιγουριά ότι οι μεταβλητές δεν είναι ανεξάρτητες), συμπερνούμε ότι η τιμή λιανικής πώλησης εξαρτάται από το αν το προϊόν είναι ή δεν είναι κατσαρόλα, ο χρόνος γυαλίσματος εξαρτάται από το αν το προϊόν είναι ή δεν είναι κατσαρόλα και η διάμετρος εξαρτάται από το αν το προϊόν είναι ή δεν είναι δίσκος.


Παραθέτοντας παρακάτω ένα γράφημα για κάθε ποσοτική μεταβλητή, αποκαλύπτεται η αναμενόμενη τιμή διαμέτρου, χρόνου γυαλίσματος και τιμής λιανικής πώλησης ανά κατηγορία.

Σχήμα 2: Μέση διάμετρος ανά κατηγορία σκεύους




Όπως φαίνεται στο παραπάνω σχήμα, ένας δίσκος αναμένεται να έχει μεγαλύτερη διάμετρο από ότι τα υπόλοιπα προϊόντα, ενώ τα πιάτα έχουν τη μικρότερη.

Σχήμα 3: Μέσος χρόνος γυαλίσματος ανά κατηγορία σκεύους



Στο παραπάνω γράφημα βλέπουμε ότι μία κατσαρόλα και ένας δίσκος χρειάζονται περισσότερο χρόνο γυαλίσματος από ότι τα μπωλ και τα πιάτα.

Σχήμα 4: Μέση τιμή λιανικής πώλησης ανά κατηγορία σκεύους



Στο Σχήμα 4, φαίνεται ότι το πιο ακριβό σκεύος είναι η κατσαρόλα και το αμέσως επόμενο πιο ακριβό είναι ο δίσκος.

4. Προβλεπτικά ή ερμηνευτικά μοντέλα

Έχοντας αναλύσει τις ανά δύο σχέσεις των μεταβλητών, θέλουμε να φτιάξουμε ένα μοντέλο ώστε να μπορούμε να ερμηνεύσουμε τις πιθανές διαφορές των προϊόντων στη διάμετρο. Επιπλέον θα επιδιώξουμε να δημιουργήσουμε προβλεπτικά μοντέλα τα οποία θα μπορούν να μας δώσουν μία αναμενόμενη τιμή για το χρόνο γυαλίσματος και τη τιμή λιανικής πώλησης ενός προϊόντος ανάλογα με τα χαρακτηριστικά του.

Πρώτα από όλα, θα πραγματοποιηθούν κάποιοι έλεγχοι υποθέσεων που θα έχουν ως στόχο την περαιτέρω διερεύνηση των σχέσεων μεταξύ των ποσοτικών μας μεταβλητών και το είδος κάθε σκεύους. Από τα τεστ κανονικότητας βλέπουμε ότι η μεταβλητή DIAM ακολουθεί την κανονική κατανομή για κάθε ένα από τα είδη των προϊόντων. Όμως ελέγχοντας την κανονικότητα για τη μεταβλητή TIME βλέπουμε ότι απορρίπτεται η κανονικότητα στη κατηγορία BOWL (LillieTest p-value=0.04166) όπως απορρίπτεται και για τη μεταβλητή PRICE στη κατηγορία BOWL (Shapiro-Wilk Test p-value=0.04507). Στη συνέχεια θα ελέγξουμε αν οι διαφορές των μέσων ανά κατηγορία είναι

στατιστικά σημαντικές. Βλέπουμε ότι ο μέσος χρόνος γυαλίσματος που χρειάζεται ένα σκεύος κατηγορίας BOWL διαφέρει από το χρόνο που χρειάζονται τα υπόλοιπα σκεύη (WilcoxonTest p-value=0.002894). Επομένως, το αν είναι ή όχι BOWL το προϊόν επηρεάζει τον χρόνο γυαλίσματος. Επίσης το αν είναι BOWL επηρεάζει στατιστικά σημαντικά και τη διάμετρο του προϊόντος (WilcoxonTest p-value=0.01526). Επίσης, και οι τρεις ποσοτικές μεταβλητές επηρεάζονται στατιστικά σημαντικά από το αν είναι ή όχι το σκεύος κατσαρόλα (WilcoxonTest p-values<0.05).

Στη συνέχεια, γνωρίζοντας ποιες σχέσεις ακολουθούν τη κανονική κατανομή, αυτό που θέλουμε να ελέγξουμε είναι η ομοσκεδαστικότητα, δηλαδή αν έχουν ίδιες διακυμάνσεις. Κάνοντας τον έλεγχο ίσων διακυμάνσεων για τις μεταβλητές DIAM, TIME και PRICE στην κατηγορία προϊόντος DISH βλέπουμε ότι δεν έχουμε ένδειξη απόρριψης της ομοσκεδαστικότητας (BartlettTest p-value>0.05). Όμως η μεταβλητή διάμετρος στην κατηγορία της κατσαρόλας φαίνεται ότι δεν έχει ίσες διακυμάνσεις (BartlettTest p-value=0.01637) όπως δεν έχει και στη κατηγορία του δίσκου (BartlettTest p-value=0.004675). Επίσης, η υπόθεση της ομοσκεδαστικότητας απορρίπτεται και για τη μεταβλητή PRICE στη κατηγορία BOWL (LeveneTest=0.034). Μετά από αυτό, θέλουμε να δούμε αν η κατηγορία σκεύους επηρεάζει τη μέση τιμή των δεδομένων μας στο χρόνο και τη τιμή λιανικής πώλησης. Συμπεραίνουμε ότι ο μέσος χρόνος γυαλίσματος της κατηγορίας πιάτου δε διαφέρει σημαντικά από των άλλων κατηγοριών (T-test p-value=0.8807) αλλά δε διαφέρει σημαντικά ούτε αυτός της κατηγορίας δίσκου από τις άλλες κατηγορίες (T-test p-value=0.09455). Επίσης η μέσης τιμή λιανικής πώλησης δεν διαφέρει στατιστικά σημαντικά στις συγκεκριμένες κατηγορίες από τις υπόλοιπες (T-test p-value=0.6541 & T-test p-value=0.2482). Τέλος μας ενδιαφέρει να δούμε με ποιες κατηγορίες η μεταβλητή price έχει στατιστικά σημαντική σχέση. Καταλήγουμε ότι με τις κατηγορίες BOWL και CASS δεν έχει σημαντική σχέση (TukeyTest p-value=0.0224 & TukeyTest p-value<0.001) ενώ με τις κατηγορίες DISH και TRAY οι σχέσεις είναι σημαντικές (TukeyTest p-value=0.7363 & TukeyTest p-value=0.0828).

Εφόσον έχουμε πραγματοποιήσει λεπτομερή έλεγχο στα δεδομένα μας και έχουμε κατανοήσει σε μεγάλο βαθμό τις σχέσεις που έχουν οι μεταβλητές μεταξύ τους, είμαστε σε θέση πλέον να μπορούμε να προσαρμόσουμε ερμηνευτικά και προβλεπτικά μοντέλα για τις ποσοτικές μας μεταβλητές. Τα πλήρη μοντέλα για κάθε μία από τις ποσοτικές μεταβλητές θα είναι της παρακάτω μορφής:

- $DIAM = \beta_0 + \beta_1 * TIME + \beta_2 * PRICE + \beta_3 * BOWL + \beta_4 * CASS + \beta_5 * DISH + \beta_6 * TRAY$
- $TIME = \beta_0 + \beta_1 * DIAM + \beta_2 * PRICE + \beta_3 * BOWL + \beta_4 * CASS + \beta_5 * DISH + \beta_6 * TRAY$
- $PRICE = \beta_0 + \beta_1 * DIAM + \beta_2 * TIME + \beta_3 * BOWL + \beta_4 * CASS + \beta_5 * DISH + \beta_6 * TRAY$

Όπου το β_0 θα είναι μία σταθερά για κάθε μοντέλο και τα $\beta_1, \beta_2, \beta_3, \beta_4, \beta_5, \beta_6$ θα είναι οι συντελεστές των μεταβλητών.

Αρχικά θα μελετήσουμε το μοντέλο της μεταβλητής DIAM.

Πίνακας 3: Στοιχεία του πλήρους μοντέλου της μεταβλητής DIAM

	Estimate	Std.Error	t value	Pr(> t)
Intercept	7.70	0.78	9.82	<0.01
TIME	-0.06	0.04	-1.67	0.10
PRICE	0.08	0.01	6.30	<0.01
BOWL	-2.16	0.78	-2.76	<0.01
CASS	-3.14	1.04	-3.01	<0.01
DISH	-3.27	1.02	-3.22	<0.01
TRAY	0.37	1.01	0.37	0.72

Το προσαρμοσμένο R^2 (R^2 adj) σε αυτό το μοντέλο είναι 0.7356 που σημαίνει ότι οι ανεξάρτητες μεταβλητές εξηγούν την εξαρτημένη μεταβλητή σε ποσοστό κοντά στο 74%. Στην προσπάθειά μας να βρούμε ένα καλό μοντέλο θα χρησιμοποιήσουμε και κριτήρια όπως το AIC (Akaike Information Criterion) το οποίο εκτιμά το σφάλμα πρόβλεψης. Το AIC για το πλήρες μας μοντέλο είναι 87.21. Στην τελευταία στήλη του παραπάνω πίνακα παρατηρούμε ότι τα p-values των μεταβλητών TIME και TRAY είναι αρκετά μεγάλα σε αντίθεση με τα υπόλοιπα που είναι κοντά στο 0. Αυτό σημαίνει ότι η σχέση τους με τη διάμετρο των προϊόντων δεν είναι ιδιαίτερα σημαντική, με αποτέλεσμα να μη προσφέρουν πολλή πληροφορία στο μοντέλο μας. Άρα, καλό θα ήταν να τις αφαιρέσουμε.

Πίνακας 4: Στοιχεία τελικού μοντέλου της μεταβλητής DIAM

	Estimate	Std.Error	t value	Pr(> t)
Intercept	7.24	0.67	10.79	<0.01
PRICE	0.06	<0.01	11.03	<0.01
BOWL	-2.06	0.63	-3.29	<0.01
CASS	-3.33	0.83	-4.01	<0.01
DISH	-3.42	0.88	-3.88	<0.01

Το R^2 adj στο τελικό μας μοντέλο είναι 0.7317, δηλαδή ελάχιστα μικρότερο από ότι στο πλήρες. Βλέπουμε ότι η εκτιμώμενη παράμετρος της μεταβλητής PRICE είναι 0.06. Αυτό σημαίνει ότι για κάθε επιπλέον δολάριο στη τιμή λιανικής πώλησης, η διάμετρος του σκεύους αναμένεται να μεγαλώσει κατά 0.06 ίντσα. Επίσης, η παράμετρος της μεταβλητής BOWL έχει τη τιμή -2.06. Η μετάφραση αυτής είναι πως αν ξέρουμε ότι το σκεύος είναι μπωλ, η αναμενόμενη διάμετρος θα είναι 2.06 ίντσες μικρότερη. Συνεχίζοντας με τις παραμέτρους, η μεταβλητή CASS έχει παράμετρο -3.33 που σημαίνει ότι αν μας δοθεί ότι το σκεύος είναι κατσαρόλα, περιμένουμε διάμετρο προϊόντος μικρότερη κατά 3.33 ίντσες. Τέλος, η παράμετρος της μεταβλητής DISH είναι -3.42, το οποίο σημαίνει ότι για σκεύος κατηγορίας πιάτου περιμένουμε διάμετρο μικρότερη κατά 3.42 ίντσες. Το AIC για το διορθωμένο μοντέλο είναι 86.3, μικρότερο, επομένως βελτιωμένο από ότι στο πλήρες. Αφαιρώντας και τη σταθερά, αποκτά σωστή φυσική ερμηνεία το μοντέλο, αφού ένα σκεύος μηδενικής τιμής που δεν ανήκει στη

κατηγορία των μπωλ, κατσαρόλα και πιάτο θα έχει μηδενική διάμετρο. Θέλοντας όμως να βελτιώσουμε κι άλλο τις προβλέψεις μας πρέπει να επιχειρήσουμε να μειώσουμε και άλλο το AIC. Ύστερα από δοκιμές κάποιον μετασχηματισμών καταλήγουμε στο ότι αν λογαριθμίσουμε τις μεταβλητές διαμέτρου και τιμής, το AIC γίνεται -219.52, σαφώς καλύτερο από πριν. Έτσι το τελικό προβλεπτικό μοντέλο βρίσκουμε ότι θα είναι το εξής:

$$\log(\text{DIAM})=0.2+0.54*\log(\text{PRICE})-0.21*\text{BOWL}-0.30*\text{CASS}-0.35*\text{DISH}$$

Έχοντας μελετήσει επαρκώς μοντέλα για τη μεταβλητή DIAM, προχωράμε στη μεταβλητή TIME

Πίνακας 5: Στοιχεία του πλήρους μοντέλου της μεταβλητής TIME

	Estimate	Std.Error	t value	Pr(> t)
Intercept	12.58	4.44	2.83	<0.01
DIAM	-0.81	0.49	-1.67	0.10
PRICE	0.36	0.04	9.59	<0.01
BOWL	-2.26	3.00	-0.75	0.45
CASS	1.53	4.06	0.38	0.71
DISH	0.55	4.01	0.14	0.89
TRAY	7.70	3.50	2.20	0.03

Το R^2 adj σε αυτό το μοντέλο είναι 0.8592 και το AIC 238.44. Παρατηρούμε ότι μόνο η σταθερά και η μεταβλητή της τιμής λιανικής πώλησης έχουν p-value που προσεγγίζει το 0. Επομένως, θα μπορούσαμε να δημιουργήσουμε ένα μοντέλο που θα έχει μόνο αυτές τις δύο παραμέτρους.

Πίνακας 6: Στοιχεία του τελικού μοντέλου της μεταβλητής TIME

	Estimate	Std.Error	t value	Pr(> t)
Intercept	6.54	1.93	3.39	<0.01
PRICE	0.34	0.02	17.61	<0.01

Το R^2 adj είναι 0.842, δηλαδή μικρότερο από του πλήρες μοντέλου κατά πολύ λίγο παρόλο που αφαιρέθηκαν 5 παράμετροι. Το AIC έγινε 240.66, δηλαδή ούτε εκείνο άλλαξε σημαντικά. Προχωρώντας τώρα στην ερμηνεία των δύο μοναδικών παραμέτρων, η σταθερά έχει τη τιμή 6.54. Αυτό σημαίνει ότι ένα προϊόν μηδενικού κόστους χρειάζεται 6.54 λεπτά για το γυαλισμά του. Επιπροσθέτως, η τιμή της παραμέτρου της μεταβλητής PRICE είναι 0.34, που σημαίνει ότι για κάθε επιπλέον δολάριο που θα έχει η τιμή του σκεύους, αναμένεται 0.34 λεπτό χρόνου γυαλισματος επιπλέον. Θέλοντας τώρα να βρούμε ένα πιο κατάλληλο μοντέλο για προβλέψεις, καταλήγουμε στο ότι πρέπει να λογαριθμίσουμε τη μεταβλητή TIME. Με αυτόν τον τρόπο το AIC γίνεται -173.41 και βρίσκουμε ότι το τελικό προβλεπτικό μοντέλο θα είναι το εξής:

$$\log(\text{TIME})=2.74+0.08*\text{TIME}$$

Αφού μελετήσαμε και το μοντέλο της μεταβλητής TIME, θα μελετήσουμε και αυτό της μεταβλητής PRICE.

Πίνακας 7: Στοιχεία του πλήρους μοντέλου της μεταβλητής PRICE

	Estimate	Std.Error	t value	Pr(> t)
Intercept	-42.96	8.66	-4.96	<0.01
DIAM	5.22	0.83	6.30	<0.01
TIME	1.76	0.18	9.59	<0.01
BOWL	13.35	6.38	2.09	0.04
CASS	19.79	8.53	2.32	0.02
DISH	15.11	8.58	1.76	0.08
TRAY	-6.37	8.00	-0.79	0.43

Το R^2 adj του πλήρους μοντέλου είναι 0.9072 και το AIC του 331.56. Στο μοντέλο αυτό φαίνεται ότι τα p-values των παραμέτρων της σταθεράς, της διαμέτρου και του χρόνου γυαλίσματος προσεγγίζουν το 0 και άρα είναι σημαντικά για το μοντέλο μας. Οι υπόλοιπες παράμετροι, δηλαδή εκείνες των κατηγορικών μεταβλητών, μπορούν και να αφαιρεθούν.

Πίνακας 8: Στοιχεία του τελικού μοντέλου της μεταβλητής PRICE

	Estimate	Std.Error	t value	Pr(> t)
Intercept	-26.02	6.90	-3.77	<0.01
DIAM	3.96	0.83	4.75	<0.01
TIME	1.93	0.17	11.43	<0.01


Στο τελικό μοντέλο το R^2 adj είναι 0.8853, δηλαδή μόλις κατά 0.0219 μικρότερο από ότι στο πλήρες μοντέλο και το AIC δεν αυξήθηκε ούτε 10 μονάδες (AIC=340.44). Η σταθερά εδώ μας λέει την αναμενόμενη τιμή λιανικής πώλησης ενός προϊόντος μηδενικής διαμέτρου που χρειάζεται μηδενικό χρόνο γυαλίσματος. Θεωρητικά, θα έπρεπε να είναι 0, οπότε προσθέτοντας το 26.02 στην εξαρτημένη μεταβλητή, η σταθερά γίνεται 0 και η ερμηνεία γίνεται σωστή χωρίς να επηρεαστεί κάποια άλλη τιμή. Η εκτιμώμενη παράμετρος της μεταβλητής DIAM έχει τη τιμή 3.96, δηλαδή δύο προϊόντα με μία ίντσα διαφορά, αναμένεται να έχουν 3.96 δολάρια διαφορά στη τιμή τους, με το μεγαλύτερο σε διάμετρο φυσικά να πωλείται και ακριβότερα. Για τη παράμετρο της μεταβλητής TIME έχει εκτιμηθεί η τιμή 1.93 που σημαίνει πως για κάθε επιπλέον λεπτό χρόνου γυαλίσματος που θα χρειαστεί ένα σκεύος αναμένεται να κοστίζει 1.93 παραπάνω δολάρια. Δοκιμάζοντας μετασχηματισμούς με σκοπό την εύρεση ενός μοντέλου με χαμηλό AIC βρίσκουμε ότι το μοντέλο με λογαριθμικές τις τιμές, της τιμής λιανικής πώλησης, της διαμέτρου και του χρόνου θα έχει AIC=-170.99, δηλαδή πολύ χαμηλό. Το μοντέλο αυτό θα είναι το εξής:

$$\log(\text{PRICE})=0.1+0.77*\log(\text{DIAM})+0.69*\log(\text{TIME})$$


5. Συμπεράσματα και συζήτηση

Έχοντας πλέον ολοκληρώσει τη μελέτη μας έχουμε αποκτήσει ιδιαίτερα χρήσιμες γνώσεις όσον αφορά τα προϊόντα της Nambe Mills. Είμαστε σε θέση πλέον να μπορούμε να ερμηνεύσουμε τις σχέσεις μεταξύ των μεταβλητών αλλά και να προβλέψουμε τη διάμετρο, το χρόνο γυαλίσματος και τη τιμή λιανικής πώλησής τους γνωρίζοντας μόνο μερικά από τα χαρακτηριστικά τους. Ένα από τα πολύ ενδιαφέροντα συμπεράσματά μας είναι ότι η διάμετρος ενός σκεύους δεν έχει σημαντική σχέση με το χρόνο που θα χρειαστεί ένα σκεύος για να γυαλιστεί, αλλά όσο μεγαλύτερη είναι η τιμή λιανικής πώλησης του σκεύους, τόσο μεγαλύτερη αναμένεται και η διάμετρος. Επίσης ανακαλύψαμε πως όσο περισσότερος χρόνος γυαλίσματος και όσο μεγαλύτερη η διάμετρος ενός προϊόντος τόσο μεγαλύτερη θα είναι και η τιμή λιανικής πώλησης. Επομένως, η εταιρία γνωρίζει ότι εάν χρειάζεται να μειώσει τις τιμές της για να έχει περισσότερες πωλήσεις, θα πρέπει να μειώσει τις διαμέτρους και τους χρόνους γυαλίσματος των προϊόντων. Άρα για όποια απόφαση χρειαστεί να πάρει στο μέλλον η εταιρία, θα μπορεί να λάβει υπόψη της την έρευνα αυτή για να έχει πιο αποτελεσματικές απόρροιας.


Παράρτημα




Σχήμα 5: Πίτα συχνοτήτων κατηγορικών μεταβλητών όπως εμφανίζεται στην R




Σχήμα 6: Ραβδόγραμμα και διάγραμμα πλαισίου-απολήξεων για τη μεταβλητή DIAM




Σχήμα 7: Ραβδόγραμμα και διάγραμμα πλαισίου-απολήξεων για τη μεταβλητή TIME




Σχήμα 8: Ραβδόγραμμα και διάγραμμα πλαισίου-απολήξεων για τη μεταβλητή PRICE




Σχήμα 9: QQ-Plot για κάθε μία από τις ποσοτικές μεταβλητές




Σχήμα 10: QQ-Plot για τις μεταβλητές diam και bowl




Σχήμα 11: QQ-Plot για τις μεταβλητές diam και cass




Σχήμα 12: QQ-Plot για τις μεταβλητές diam και dish




Σχήμα 13: QQ-Plot για τις μεταβλητές *diam* και *tray*




Σχήμα 14: QQ-Plot για τις μεταβλητές *diam* και *time*




Σχήμα 15: QQ-Plot για τις μεταβλητές *diam* και *price*



Σχήμα 16: QQ-Plot για τις μεταβλητές *time* και *bowl*




Σχήμα 17: QQ-Plot για τις μεταβλητές time και cass




Σχήμα 18: QQ-Plot για τις μεταβλητές time και dish

Normal qqplot of time and tray




Σχήμα 19: QQ-Plot για τις μεταβλητές time και tray

Normal qqplot of time and price




Σχήμα 20: QQ-Plot για τις μεταβλητές time και price

Normal qqplot of price and bowl




Σχήμα 21: QQ-Plot για τις μεταβλητές price και bowl

Normal qqplot of price and cass




Σχήμα 22: QQ-Plot για τις μεταβλητές price και cass

Normal qqplot of price and dish




Σχήμα 23: QQ-Plot για τις μεταβλητές price και dish

Normal qqplot of price and tray




Σχήμα 24: QQ-Plot για τις μεταβλητές price και tray



Σχήμα 25: Διάγραμμα για τις μεταβλητές *diam* και *time*




Σχήμα 26: Διάγραμμα για τις μεταβλητές *diam* και *price*




Σχήμα 27: Διάγραμμα για τις μεταβλητές *time* και *price*


barplot for diam of variable bowl




barplot for diam of variable cass



barplot for diam of variable dish




barplot for diam of variable tray




Σχήμα 28: Ραβδόγραμμα διαμέτρου για κάθε τύπο σκεύους χωριστά


barplot for time of variable bowl




barplot for time of variable cass



barplot for time of variable dish




barplot for time of variable tray




Σχήμα 29: Ραβδόγραμμα χρόνου γυαλίσματος για κάθε τύπο σκεύους χωριστά


barplot for price of variable bowl




barplot for price of variable cass



barplot for price of variable dish




barplot for price of variable tray




Σχήμα 30: Ραβδόγραμμα τιμής λιανικής πώλησης για κάθε τύπο σκεύους χωριστά


boxplot for diam of variable bowl




boxplot for diam of variable cass



boxplot for diam of variable dish




boxplot for diam of variable tray




Σχήμα 31: Διάγραμμα πλαισίου-απολήξεων διαμέτρου για κάθε τύπο σκεύους χωριστά


boxplot for time of variable bowl




boxplot for time of variable cass



boxplot for time of variable dish




boxplot for time of variable tray




Σχήμα 32: Διάγραμμα πλαισίου-απολήξεων χρόνου γυαλίσματος για κάθε τύπο σκεύους χωριστά


boxplot for price of variable bowl




boxplot for price of variable cass







boxplot for price of variable dish




boxplot for price of variable tray




Σχήμα 33: Διάγραμμα πλαισίου-απολήξεων τιμής λιανικής πώλησης για κάθε τύπο σκεύους χωριστά



Σχήμα 34: Διάγραμμα *plotmeans* της μεταβλητής *DIAM* για κάθε τύπο σκεύους χωριστά



Σχήμα 35: Διάγραμμα *plotmeans* της μεταβλητής TIME για κάθε τύπο σκεύους χωριστά



Σχήμα 36: Διάγραμμα *plotmeans* για τη μεταβλητή PRICE για κάθε τύπο σκεύους χωριστά